ALFRED · WORKFLOW DE RECORDATORIOS Y RECOMENDACIONES

Empecé por sus reseñas, no por la arquitectura

Antes de diseñar nada leí lo que los usuarios ya dijeron: el recordatorio y el pickup gustan; lo que rompe la confianza es un dato equivocado —un SOAT (Seguro Obligatorio de Accidentes de Tránsito) marcado vencido estando al día—. Ese detalle mandó todo el diseño.

ALFRED · FLUJO END-TO-END

Detección determinística + IA (inteligencia artificial) candidata + fulfillment con evidencia

Evento del vehículo → elegibilidad → categoría → relevancia → notificación (canal por preferencia + consentimiento + urgencia) → recomendación → proveedor → booking → ejecución física → feedback. Dos puertas deterministas (elegibilidad, relevancia) antes de cualquier ranking de IA; el cobro nunca lo decide la IA.

Determinístico · gate = filtro ¿pasa? · IA · candidato · Feedback / reintento · sí / pasa · no



REGLA DE ORO

La IA nunca decide elegibilidad, relevancia ni cobro (`Booking.charged_at`): solo rankea, personaliza o explica; cada puerta —elegibilidad, categoría, relevancia, confirmación del cobro— es 100% determinística. Y aprende del feedback: cada descarte con motivo (`dismiss_reason`) suprime a futuro (auditado en `ReminderEvaluation`, append-only), alimenta el ranking (`RecSignal`) o marca el servicio como ya hecho (`VehicleServiceState` → `resolved`).

SERVICECATALOG · 6 CATEGORÍAS

Alfred no es "solo SOAT" — la categoría decide el motor

Todo servicio vive en el catálogo canónico. Su `category` — determinística, nunca decidida por IA — define si es **Reminder** (necesidad/obligación) o **Recommendation** (deseo), y cuánto personaliza la IA. Esta es la decisión d2 del flujo de arriba.

CATEGORY	MOTOR	NATURALEZA
legal_documental	Reminder	necesidad · obligación legal
mantenimiento_preventivo	Reminder	necesidad · técnica (deriva de plan)
seguridad_equipamiento	Reminder	necesidad · caduca
reparacion_correctiva	Booking / Reminder	necesidad · reacción a falla
cuidado_estetico	Recommendation	deseo · discrecional por hábito
accesorio_equipamiento	Recommendation	deseo · marketplace de producto

Un ítem discrecional (deseo) nunca se presenta como necesidad u obligación — esta frontera hace estructuralmente imposible el upsell sin fundamento.

La IA monetiza en un carril sin tocar el otro

Dos carriles que nunca se mezclan. A la izquierda, lo que Alfred le debe al dueño del vehículo por evidencia — nunca se cobra por aparecer ahí. A la derecha, lo que Alfred le vende con permiso — la IA rankea por afinidad, el dinero solo define qué aliados entran al catálogo. La barrera del centro es la regla de oro hecha estructura: ningún peso cruza de un carril al otro.

Carril de confianza

determinístico · IA · B2B

Legal (SOAT, RTM —revisión técnico-mecánica—, impuesto) · Mantenimiento preventivo · Reparación correctiva · Seguridad obligatoria.

Anticipa la falla — la salud de tu flota te dice qué atender primero.

Salud de flota

Problema	Flota gestionada de forma reactiva, sin vista de riesgo agregada — 50% del negocio de Alfred es B2B (venta a empresas).
Por qué IA	Health score predictivo, multi-señal con pesos aprendidos — no una regla de fecha fija (esa ya basta para lo legal).
Datos	Kilometraje, historial de servicio, edad, patrón de uso, vencimientos, frescura del dato, historial del proveedor.
Alcance mínimo viable	Score + priorización + explicación en 1-2 flotas piloto; sin auto-agendamiento ni ruteo logístico.
Implementación	Heurística ponderada propia → un modelo de aprendizaje automático (gradient boosting) entrenado con datos reales; se recalcula de noche por lotes; el camino determinístico sigue si la IA falla.
Riesgo y salvaguardas	Política de presupuesto/talleres aprobados como gate duro; gestor aprueba antes de agendar; solo agregados anonimizados por cohorte.
Validación	Offline (backtest histórico) → shadow (auditado) → A/B (flotas piloto vs control); no escala si rompe política o cae adherencia; umbrales a definir con volumen real.

— EL DINERO NO CRUZA —

Carril comercial

discrecional · IA · B2C

Cuidado estético (detailing, lavado) · Accesorios y equipamiento no obligatorio.

Acceso exclusivo: una vitrina curada de aliados, a la medida de tu carro y tu estilo.

Vitrina exclusiva

Problema	Monetización adicional sin volverse el actor que recomienda sin necesidad; catálogo discrecional sin distribución personalizada.
Por qué IA	Ranking de afinidad cruza perfil del dueño y del vehículo; en catálogos pequeños, un orden simple casi basta.
Datos	Perfil del vehículo (Vehicle DNA), perfil de afinidad del dueño (Driver DNA), catálogo del proveedor y su membresía de aliado (curada por evaluación de calidad).
Alcance mínimo viable	Solo 2 categorías — cuidado estético y accesorios; sin subastas ni LLM (modelo de lenguaje grande) generativo; arranca en cuentas B2C (consumidor final) individuales.
Implementación	Ranking in-house, heurística → modelo propio con historial de aceptación; recae en orden por relevancia si la IA falla.
Riesgo y salvaguardas	Gate de 4 capas — categoría, relevancia, el orden lo gobierna solo la afinidad, cobro determinístico; la IA nunca decide qué se muestra. La membresía de aliado es **curada**: se entra aprobando una **evaluación de calidad**, no solo pagando — define el catálogo, nunca el orden.
Validación	Offline (contrafactual) → shadow (expone sin mostrar) → A/B (vitrina de aliados personalizada vs base); no escala si sube opt-out o cae afinidad; umbrales a definir con volumen real.

Por qué estas dos y no otras: descarté un ranking único sin separar flota de individuo —deja fuera la mitad del negocio— y una explicación generativa por LLM como pieza central, por el riesgo de alucinar en un dominio con implicaciones legales y de seguridad.

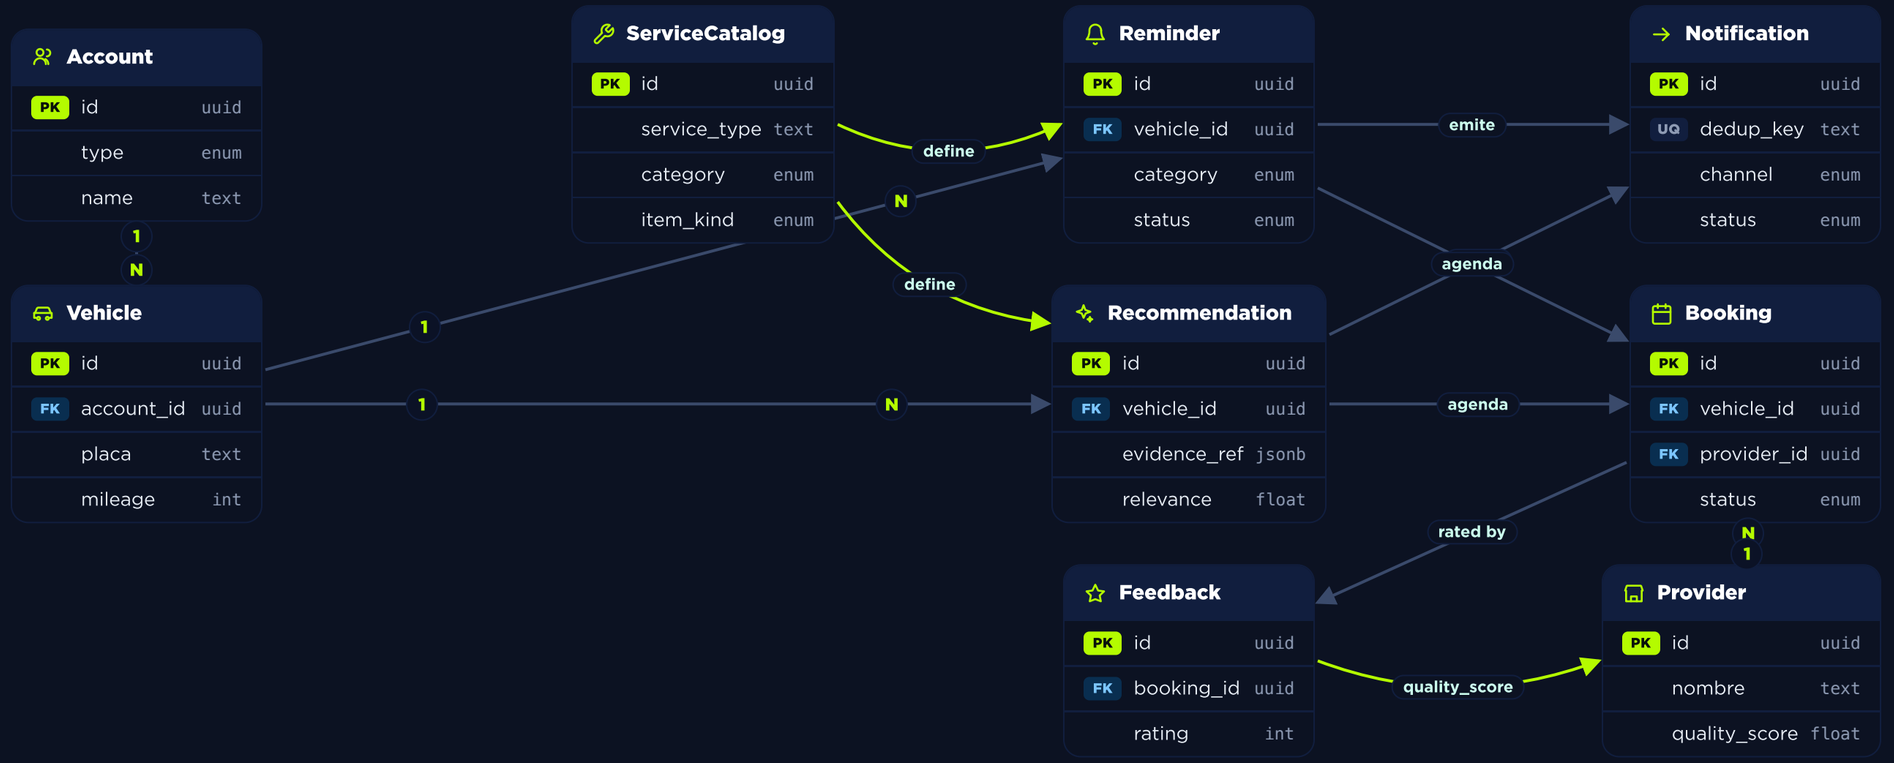
REGLA DE ORO

La IA propone: rankea, prioriza, explica. El determinístico decide: aplica política, agenda, cobra. El dinero solo define quién entra al catálogo de aliados; el orden lo gobierna la afinidad, nunca el dinero — ningún pago toca elegibilidad, orden ni seguridad, y ninguno cruza al carril de confianza.

MODELO CONCEPTUAL

Modelo de datos — núcleo

PK llave primaria · FK llave foránea · UQ campo único

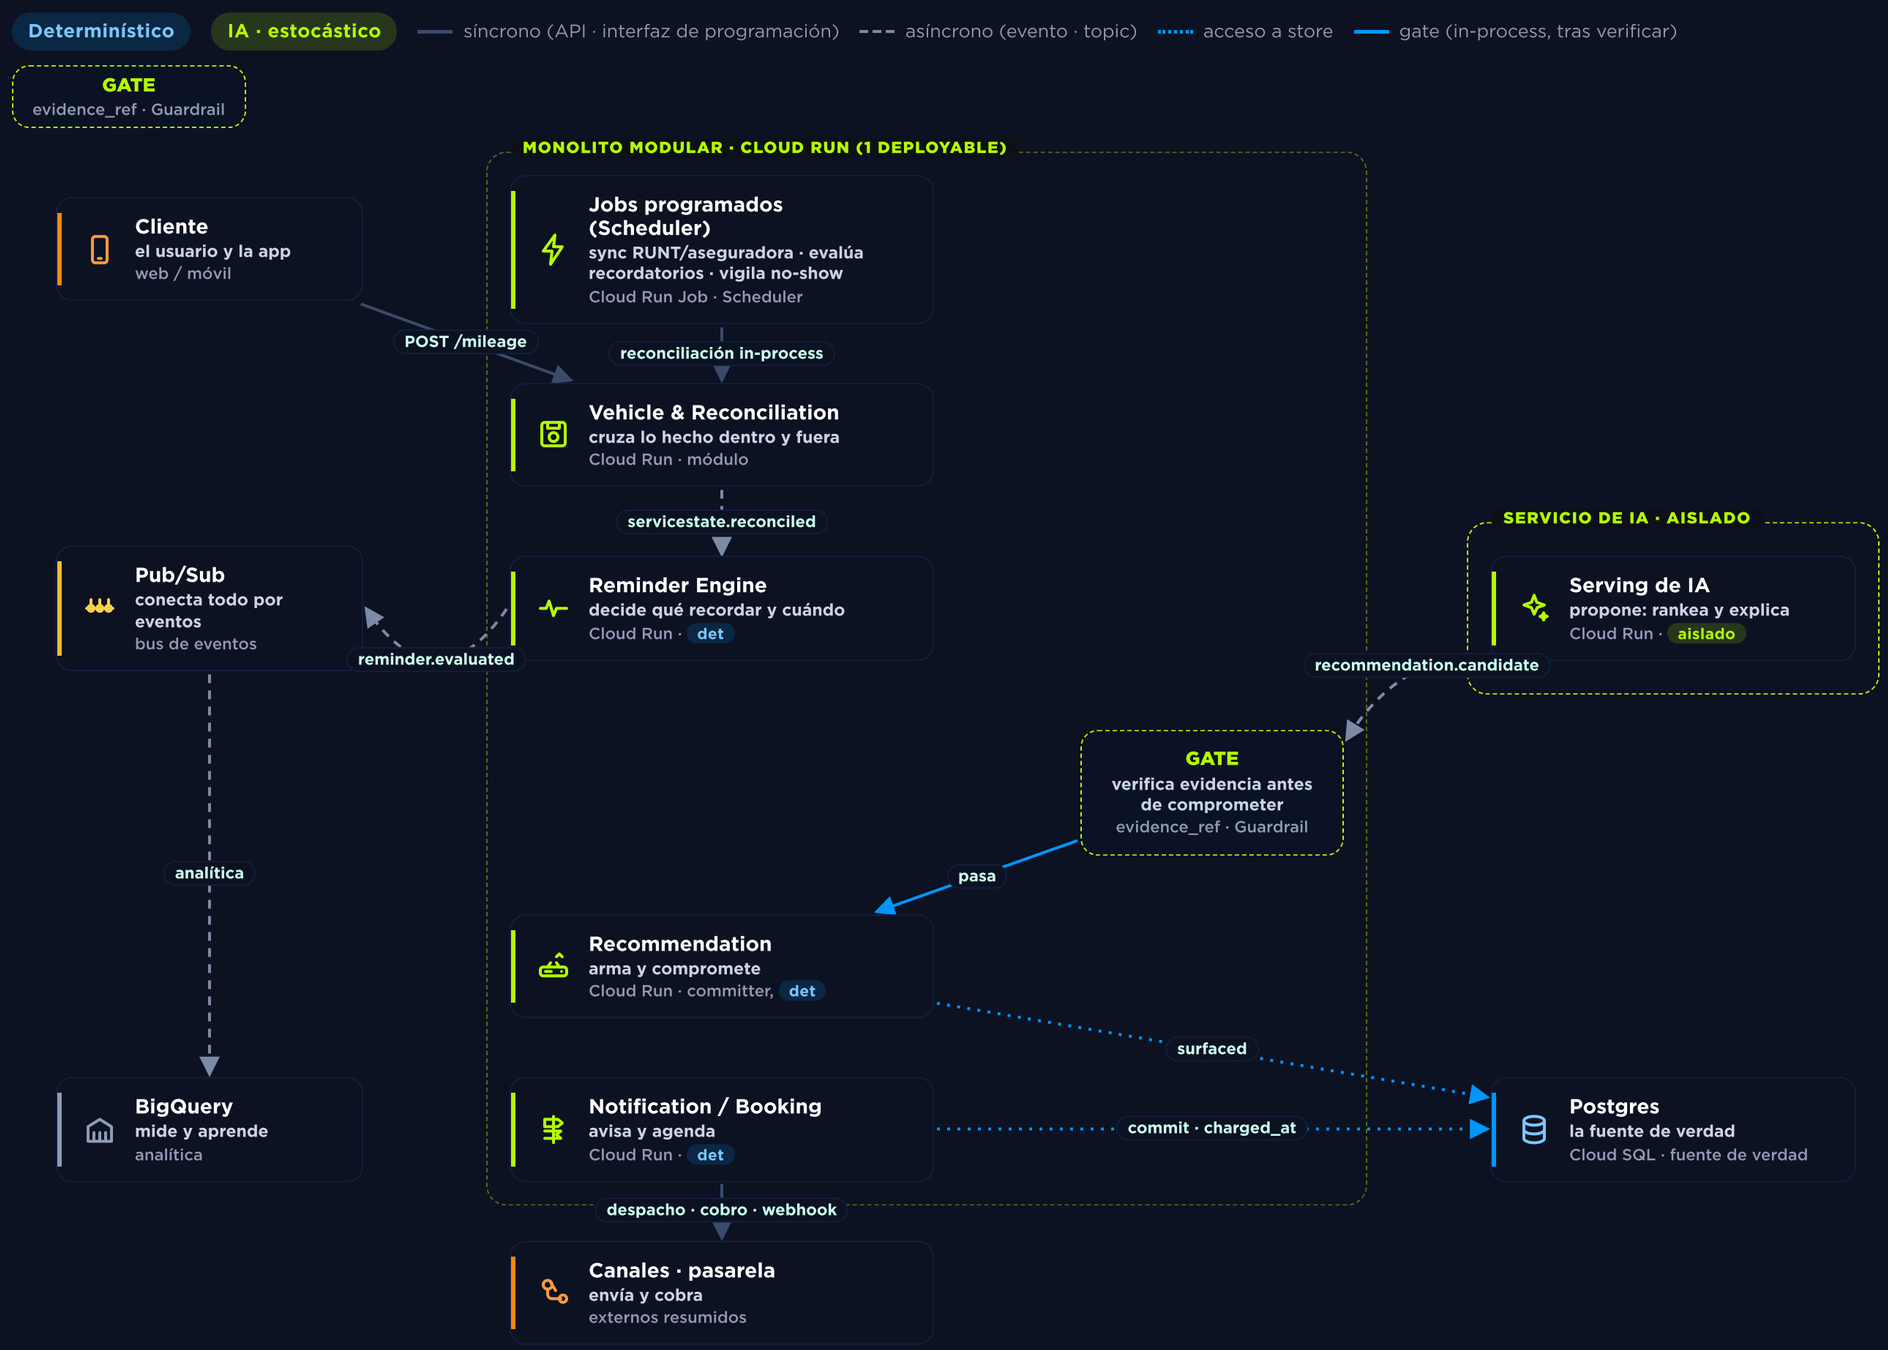


ALFRED · ARQUITECTURA — VISTA NÚCLEO

La decisión vive en el monolito; la IA solo propone

Un monolito modular —una sola cosa que desplegar y operar— concentra todo lo determinístico, y un único servicio de IA aislado que solo propone. Así, si el modelo de IA falla, el sistema degrada (recordatorios sin recomendación nueva) en vez de tumbar el cobro o la elegibilidad.

Camino caliente resumido: ingesta → reconciliación → evaluación de recordatorio y candidato de IA → gate → recomendación comprometida → notificación / reserva → analítica. El monolito modular (lima) concentra la decisión; el servicio de IA (aislado, a la derecha) solo puede proponer — nunca comprometer.



CONCERNS DE PRODUCCIÓN · TRANSVERSAL A TODA LA ARQUITECTURA

Observabilidad
Cloud Logging · Monitoring · Trace + auditoría append-only

Seguridad y acceso
RLS (seguridad por fila) en Postgres · IAM (gestión de identidad y acceso) con mínimo privilegio · Consent Boundary · sin PII (datos personales) cruda en prompts de IA

Rollout / rollback
Revisiones Cloud Run (blue-green) · expand-contract

Costo
Guardrail de gasto · BigQuery slots · model routing

Infra / HA
Cloud SQL con HA (alta disponibilidad) + PITR (recuperación a un punto en el tiempo) · Cloud Run autoscaling · Secret Manager

Modos de falla
IA cae → degrada (sin recomendación nueva), nunca frena recordatorios · proveedor no confirma → reasigna vía saga · Pub/Sub caído → reintento con backoff + cola muerta · sync RUNT stale → alerta + banner de incertidumbre, no marca vencido

REGLA DE ORO

El servicio de IA (aislado) solo publica `recommendation.candidate` de forma asíncrona. Nunca ejecuta el Guardrail ni escribe la decisión: el monolito lo consume, corre el gate — restricción de base de datos (`evidence_ref IS NOT NULL`) más la librería Guardrail in-process — y es el único que ejecuta el commit hacia `surfaced` o `charged_at`. Es, por construcción, imposible que la IA decida elegibilidad, relevancia, canal, envío o cobro.

ALFRED · TRADE-OFFS Y ESCENARIO DE PRESIÓN DE COSTOS

Tres zonas de decisión bajo presión de costo

Costo cloud +35% y deadline de 6 semanas: cada pieza del sistema cae en innegociable, recortable o diferible.

Escenario: costo cloud +35% · datos incompletos · observabilidad débil · deadline 6 semanas

EN 6 SEMANAS ENTREGAMOS

Salud de flota (health score) en 1-2 flotas piloto, en shadow/auditado · **Vitrina en shadow mode** (mide afinidad, no expone ni cobra) · Core de recordatorios determinístico **intacto**. Se difiere lo visible/monetizado, nunca el aprendizaje ni lo innegociable.

Al negocio se lo presento como una decisión ya tomada con datos —una página, las tres zonas y un check-in a la semana 3—, no como una pregunta abierta: así ve avance concreto sin reabrir el debate técnico cada sprint.

INNEGOCIABLE 5

Gate determinístico / regla de oro
todo el sistema — la IA nunca decide elegibilidad ni cobro

Trazabilidad append-only
todo el sistema — reconstruye qué se envió y por qué

Tests del camino crítico
todo el sistema — idempotencia · evita el doble cobro

Consentimiento / privacidad
todo el sistema — Ley 1581 · la PII no sale sin permiso

Alertas de falsos positivos + salud de sync
todo el sistema — detector temprano del falso positivo

RECORTABLE 7

Routing de modelo barato→caro
inferencia
modelo chico para lo simple · −orden de magnitud

Cache semántico de inferencia
inferencia — no recomputa respuestas repetidas · −30–70%

Batch + cache de prompt
inferencia — lo no urgente en lote · ~25% del base

Degradación de canal
canales
el canal más barato que sirva · evita SMS (mensaje de texto)/voz

BigQuery por niveles
analítica/obs — retención/slots por fuente · −30–50%

Autoscaling / right-sizing
Cloud Run + Pub/Sub — capacidad al uso real

Cuota por tenant + alerta 80%
gateway/tenancy — corta consumo fuera de control

DIFERIBLE 3

Vitrina visible / monetizada
Vitrina — hasta tener guardrails + observabilidad

Personalización avanzada / reentrenos frecuentes
ambas iniciativas — se activa con volumen real

Optimizadores adicionales
salud de flota — heurística basta hoy; solver luego

SUPUESTOS

Supuestos clave y preguntas abiertas que cambiarían el diseño.

Frescura RUNT / aseguradora	La sincronización llega por lote y puede quedar desactualizada. Si falla: el falso positivo de un SOAT o RTM marcado vencido estando al día. Se valida instrumentando el rezago real y alertando sobre él.
Ack real de citas	Sin feed confirmado del taller, la reserva puede quedar en un estado optimista. Si falla: una cita que el usuario cree confirmada y nunca se honra. Se valida integrando con el taller y midiendo el tiempo hasta registrar el incumplimiento.
Costo de inferencia	Hoy no hay costo base medido ni techo definido por iniciativa de IA. Si falla: gasto de inferencia sin control bajo picos de uso. Se valida con dashboards de costo por iniciativa y una cuota conservadora ajustable.
Cold start	Cuentas y flotas nuevas sin historial de servicio son la norma el primer día, no la excepción. Si falla: un score o ranking sin señal real al momento de lanzar. Se valida midiendo qué porción de cuentas arranca sin historial y cómo responde el respaldo determinístico.
Mezcla ~50% B2B	La proporción B2B y sus márgenes ajustados son estructurales, confirmados por los fundadores, no una estimación de producto. Si falla: la priorización de ambas iniciativas queda mal calibrada. Se valida contrastando contra ingresos y cuentas reales.
Salida del modo sombra	Aún falta fijar qué calidad, cobertura y tasa de falsos positivos habilita pasar de shadow a exposición real. Si falla: una vitrina o score expuestos antes de tener evidencia suficiente. Se valida con el propio volumen acumulado en shadow, no de antemano.

POR QUÉ ESTE RECORTE NO ES OPCIONAL

Cerca del 40% de los incidentes de producción provienen de deuda técnica asumida deliberadamente bajo presión de deadline (Gartner, 2025) — apagar tests u observabilidad para ganar tiempo es un falso ahorro, no una simplificación. La privacidad tampoco se negocia bajo presión: *"Toman tus datos y se los entregan a terceros como el banco Itaú... no cumplen políticas de reserva de datos."* — Gerardo Libreros, reseña en Google Maps; el motivo por el que `ConsentRecord` es innegociable incluso en la semana 6.